Задание 1. Пропущенные значения и корреляции

[1.1] Используя функцию multivariate_normal из numpy с любым random_state, сгенерировать и зафиксировать датасет dfS00, в котором есть **четыре** количественных (недискретных) признака и **1 класс** размером 1000 объектов, для одной пары признаков (A и B) которого задана корреляция r=+0.9, а остальные признаки не сопряжены друг с другом.

[1.2] Вывести в табличной форме статистику по датасету, включая
- Размерность всего датасета (объекты и признаки) - Тип каждого признака
- Количество классов и объектов в каждом из классов - Иные оценки выборки
- Число объектов с NaN по классам - Число объектов с 0 по классам

[1.3] Выполнить 1D визуализацию датасета по каждому из признаков в форме raincloud plot with jittering, рядом с которым в виде boxplot отображены медианы, межквартильные размахи (IQR) и размахи (Range), с параметрами boxplot, которые можно заменять на другие оценки выборки.

[1.4] Выполнить 2D визуализацию датасета по всем парам выбранных переменных с использованием scatterplot с параметрами визуализации, регулируемыми пользователем (цвета и толщины осей, число/шаг больших и малых рисок осей, сетка пространства, квадратность формы каждого рисунка, размер и тип шрифтов каждого типа подписей, отключаемость легенд и заглавий, прозрачность объектов), на которых отображены:
- на графиках разных пар признаков объекты классов разными по форме/цвету точками;
- на графиках с одной и той же парой переменных - диаграммы плотности распределения каждого класса по оси признака разными по цвету/прозрачности.

[1.5] Используя коэффициенты корреляции Пирсона и Спирмана, в форме heat-map таблицы оценить степень сопряженности пар признаков-переменных:
- на всем датасете - в каждом отдельном классе датасета.

[1.6] На основе исходного датасета dfS00 клонировать набор датасетов dfSdXX, в которых из исходного датасета случайным образом удалено значение заданного пользователем числа ячеек (0%, 1%, 2%, 5%, 10%, 20%, 50%, 80%). Для выбираемой пары признаков (исходно A+B) визуализировать каждый датасет dfSdXX как панно mxn рисунков scatterplot.

[1.7] На основе всех датасетов dfSdXX сгенерировать соответствующие датасеты dfSdXXmed, в которых пропуски заполнены медианой. Для выбираемой пары признаков (исходно A+B) визуализировать панно mxn рисунков scatterplot для всех dfSdXXmed и вывести как heatmap корреляции Пирсона как в пункте [1.5]

[1.8] На основе одного из датасетов dfSdXX, выбранного пользователем, сгенерировать соответствующие датасеты dfSdXXname, в котором пропуски заполнены следующими методами (name): медианами, kNN-заполнением, регрессионным заполнением, MICE-заполнением. Для dfSd00, выбранного dfSdXX и каждого из датасетов dfSdXXname вывести как heatmap корреляции Пирсона как в пункте [1.5], а также визуализировать две пары признаков, выбираемые пользователем (исходно A+B и C+D), как два панно mxn рисунков scatterplot.

[1.9] Для каждого из датасетов из пункта [1.8], включая исходный dfSd00, выполнить в форме Upset plot визуализацию (а) чисел объектов с пропущенными значениями для всех вариантов группировки пропусков по признакам, (б) чисел объектов с совпадающими значениями по признакам для всех вариантов группировки признаков.

[1.10]** На основе исходного датасета dfS00 клонировать датасет dfMNAR, в котором для каждого объекта удалены все значения призаков C и D, которые меньше признаковой медианы. Выполнить для полученного датасета пункты [1.8] и [1.9].

Задание 2. Линейная регрессия (LinReg) и дисперсионный анализ (ANOVA)

[2.1] Выбрать в качестве df0 один из датасетов из перечня:
- Iris - Palmer Archipelago (Antarctica) penguin - Wine Quality
- *Любой другой датасет, в котором есть как минимум три класса и как минимум четыре количественных (недискретных) признака.*

[2.2] Вывести в табличной форме статистику по датасету как в [1.2]

[2.3] Для всего датасета выполнить в форме Upset plot:
- визуализацию чисел объектов с пропущенными значениями для каждого варианта группировки пропусков по признакам;
- визуализацию чисел объектов с повторяющимися значениями, равными друг другу внутри одного признака, для каждого варианта группировки повторов по признакам.

[2.4] Выбрать три класса и четыре количественных (недискретных) признака.
Сформировать на их основе «отфильтрованный» датасет df0m для дальнейшего анализа, удалив из датасета все объекты, для которых не определены значения хотя бы одного из выбранных четырех количественных признаков.

[2.5] Для датасетов df0 и df0m сравнительно вывести корреляции Пирсона, как в [1.5]

[2.6] Выполнить визуализацию датасета по всем парам выбранных переменных, показав:
- на графиках разных пар признаков объекты классов разными по форме/цвету точками;
- в графиках с одной и той же парой переменных – диаграммы плотности распределения каждого класса по оси признака.

[2.7] Выбрать один класс и пару признаков, для которых визуализировать с использованием одиночного scatterplot с параметрами визуализации, регулируемыми пользователем, линию линейной регрессии с соответствующими доверительными (confidence bands) и прогнозными (predictive bands) полосами регрессий, предварительно включаемыми/отключаемыми для отображения пользователем.

[2.8] Отдельно повторно выполнить пункт [2.6], отобразив на каждом из графиков для каждого из классов линию линейной регрессии с соответствующими прогнозными (predictive bands) полосами регрессий, которые возможно опционально включить/отключить перед отображением.

[2.9] Вывести формулы каждой оцененной линейной регрессии вместе со значениями критерия R^2 и критериев Вальда, LR и score (для каждого вывести F-критерий, его степени свободы и соответствующий p-критерий).

[2.10] Визуализировать один количественный признак, выбираемый пользователем, для каждого из классов в виде raincloud plot with jittering, рядом с которым в виде boxplot отображены медианы, межквартильные размахи (IQR) и доверительные интервалы.

[2.11] Выполнить дисперсионный анализ (ANOVA) по одному из признаков, выбираемому пользователем: рассчитать общий F-критерий, его степени свободы df1 и df2 и соответствующий ему p-критерий для всех классов одновременно, а также для каждой пары классов.

[2.12]** Используя функцию multivariate_normal из numpy, отдельным блоком ipynb сгенерировать и визуализировать датасет dfG случайной формы распределения (за счет матрицы ковариаций гауссиана, без вывода цифр), в котором есть два количественных (недискретных) признака и 1 класс случайным размером 10-100 объектов.
Используя датасет dfG, повторно визуализировать dfG, добавив на визуализацию значение корреляции Пирсона, линию регрессии с соответствующими доверительными (confidence bands) и прогнозными (predictive bands) полосами регрессий.

Задание 3. Байесовские классификаторы: QDA, LDA, GNB, MDC.

[3.1] Используя функцию multivariate_normal (numpy) с любым random_state, сгенерировать датасет df1, в котором есть три класса с размером каждого класса 100 объектов и 16 количественных (недискретных) признаков. Распределения двух из трех классов должны значительно перекрывать друг друга, тогда как третий класс должен быть на расстоянии от первых двух классов.
Не забываем повторять шаги задания 1:
- ключевые характеристики датасета - корреляции
- визуализация панно scatterplot на всех парах переменных

[3.2] На основе созданного в пункте **[3.1]** датасета df1 сгенерировать отдельные дополнительные датасеты (dfrX), в которых объекты одного класса (который имеет пересечение с другим) повторены X раз (X=1, 2, 5, 10, 100, 1000 раз, с учетом исходного), а количество объектов в остальных классах оставлено неизменным.
Отдельно для датасетов dfrX восстановить в таблицу координаты следующих точек:
- центры масс каждого класса; - общий центр масс выбранных классов;
- центр отрезка, соединяющего центры масс выбранных классов.

[3.3] Выбрать пару классов (включая класс с повторенными объектами) и пару количественных признаков, определить в паре целевой класс. Используя методы LDA, QDA, Gaussian Naïve Bayes, MDC для каждого из сформированных датасетов dfrX, графически в виде панно X (датасет dfrX) на Y (метод) для каждой пары датасет-алгоритм построить индивиуальные графики с решающей функцией, разграниченные решающей линий решающей функции зоны и отдельные объекты классов. Визуализацию выполнять с отображением положения центров масс и соединяющего центры масс классов отрезок с его центральной точкой на каждом графике.

[3.4] Для каждого из решений из пункта [3.3] оценить качество работы полученных на основе LDA классификаторов, используя ROC и PR кривые и восстановив на графике кривых соответствующие каждому решению 95% доверительные полосы (Confidence bands 95%) ROC кривой бутстрепом (n=100 или больше). Для каждой кривой численно также отобразить метрику AUROC и ее доверительные интервалы CI95. Отдельно вывести графики сравнения ROC кривых всех классификаторов - LDA, QDA, GNB, MDC.
Все полученные графики возможно расположить в четыре колонки: левая колонка – визуализация пространства и решений LDA для отдельного dfrX, следующая – соответствующий этому dfrX и LDA AUROC с доверительной полосой и бутстреп линиями на одном рисунке, следующая – соответствующий этому dfrX и LDA AUPRC с доверительной полосой и бутстреп линиями на одном рисунке, правая – соответствующие этому dfrX графики с ROC кривой для всех классификаторов LDA, QDA, GNB, MDC и их доверительными полосами на одном рисунке (без отображения линий бутстрепа).

[3.5] Выбрать другой целевой класс и повторить визуализации пунктов **[3.3-3.4]**.

[3.6] Для датасета dfr10 на основе 3-fold, 5-fold, 10-fold, 20-fold, 50-fold, 100-fold кросс-валидации построить кривые AUROC и AUPRC с 95% доверительными полосами (CI95), выведя каждую кривую AUROC и AUPRC со всеми линиями кросс-валидации и с 95% доверительными полосами (CI95) как отдельный график. *# Вместо CI95 можно взять CI90, CI80 или другой квантиль доверительной полосы.*

[3.7] Для датасета dfr1 построить решения LDA на двух, четырех, восьми и шестнадцати признаках. Для каждого решения на одном графике восстановить ROC кривые с доверительными полосами 95%. Аналогично восстановить PR кривые.

[3.8*] Повторить пункт [3.3] для набора алгоритмов LDA, MDC, линейного SVM, LogReg. Повторить пункт [3.4] для алгоритма линейного SVM, сравнив его с LDA, MDC, LogReg.

https://stackoverflow.com/questions/55541254/precision-recall-curve-with-n-fold-cross-validation-showing-standard-deviation
https://stackoverflow.com/questions/29656550/how-to-plot-pr-curve-over-10-folds-of-cross-validation-in-scikit-learn

Trollface - Не забыли поставить для каждого задания прогресс-бар при исполнении ?